Влияние преобразований на прогнозирование временных рядов

Гусев Владислав Дмитриевич

1 Исследовательский вопрос

Для каких типов временных рядов применение определённых преобразований (log1p, Box-Cox, дифференцирование) приводит к улучшению качества прогнозирования?

2 Мотивация

Во многих прикладных задачах временные ряды обладают различными свойствами: трендом, сезонностью, гетероскедастичностью и шумом. Универсального подхода к предобработке не существует, поэтому важно понять, какие преобразования работают лучше для различных типов рядов.

3 Методология

Общий пайплайн исследования:

1. Сбор и предобработка набора временных рядов
2. Кластеризация рядов по форме через KNN с расстоянием DTW
3. Применение разности, логарифмирования и box-cox к полученным рядам
4. Обучение моделей прогнозирования

5. Оценка качества прогнозов
6. Сравнение результатов внутри кластеров

Цель — выявить зависимость между типом ряда (кластером) и эффективностью преобразований.

4 Гипотезы

4.1 Основная гипотеза

Преобразования по-разному влияют на качество прогнозирования в зависимости от структуры ряда.

4.2 Частные гипотезы

- Log1p улучшает прогнозы при гетероскедастичности и высокой волатильности
- Box-Cox чувствителен к параметру λ и может ухудшать прогноз при его некорректной оценке
- Дифференцирование улучшает качество прогнозов для рядов с трендом

5 Данные

Данные были взяты из датасета M4 https://forecastingdata.org/. Из него были засемплированы 101 ряд с 1990 по 2012 год. Ряды выровнены - это позволит более точно сравнивать резульаты. В каждом ряду по 324 наблюдения.

6 Кластеризация временных рядов

Используется DTW расстояние:

$$D(X, Y) = \min \sum_{(i,j) \in path} |x_i - y_j| \tag{1}$$

Далее применяется временная KMeans кластелизация. Всего оказалось 3 различных кластера - это число было выбрано методом Силуэта.

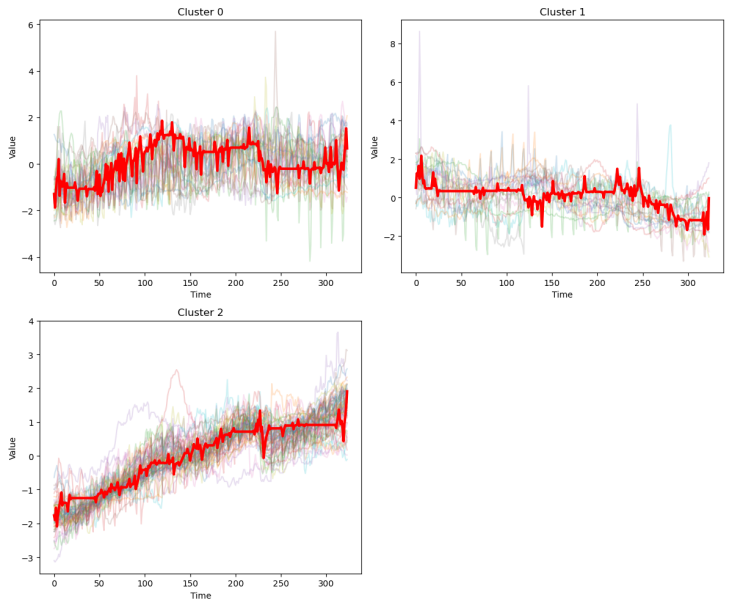

Рис. 1: Динамика рядов в разрезе 3 кластеров

7 Модели

7.1 Naive

$$\hat{y}_{t+h} = y_t \tag{2}$$

7.2 Seasonal Naive

$$\hat{y}_{t+h} = y_{t+h-m} \tag{3}$$

7.3 ETS

$$y_t = (l_{t-1} + b_{t-1})s_{t-m} + \varepsilon_t \tag{4}$$

7.4 CatBoost

$$\hat{y}_{t+h} = f(y_t, y_{t-1}, ...) \tag{5}$$

8 Преобразования

8.1 Log1p

$$z_t = \log(1 + y_t) \tag{6}$$

8.2 Box-Cox

$$z_t = \frac{y_t^\lambda - 1}{\lambda} \tag{7}$$

8.3 Differencing

$$z_t = y_t - y_{t-1} \tag{8}$$

9 Протокол валидации

Используется скользящее окно (rolling forecast origin):

- обучающее окно фиксированной длины
- прогноз на горизонт h
- сдвиг окна и повторение

Это позволяет избежать утечки данных и корректно имитировать реальное прогнозирование.

10 Метрики

$$\text{sMAPE} = \frac{2}{n} \sum_{t=1}^{n} \frac{|y_t - \hat{y}_t|}{|y_t| + |\hat{y}_t|} \tag{9}$$

Метрики считаются:

- для каждого ряда
- затем усредняются внутри кластеров

11 Feature Engineering

11.1 Даты

Из даты ряда были взяты год, месяц и день

12 Back-transformation

12.1 Log

$$\hat{y}_t = \exp(\hat{z}_t) - 1 \tag{10}$$

12.2 Bias correction

$$\hat{y}_t = \exp(\hat{z}_t + \sigma^2/2) - 1 \tag{11}$$

13 Дизайн эксперимента

Для каждого ряда выполняется:

1. Применение каждого преобразования
2. Обучение всех моделей
3. Оценка качества
4. Сравнение с базовым вариантом (без преобразования)

Таким образом, обеспечивается честное сравнение:

- одинаковые данные
- одинаковые модели
- различаются только преобразования

14 Результаты

Таблица 1: Сравнение моделей и трансформаций по метрике sMAPE (в разрезе кластеров)

Кластер	Трансформация	AutoETS	AutoTheta	Naive	SeasonalNaive
4*Cluster 0	None	1.7688	1.7187	3.6162	2.2007
	Diff	**1.4868**	2.0879	13.9002	**1.7255**
	Box-Cox	1.7266	**1.6797**	3.7129	2.2000
	Log1p	1.7572	1.7167	3.6162	2.2007
4*Cluster 1	None	**1.5021**	1.6293	2.6887	1.7766
	Diff	1.5273	2.2081	6.4407	**1.5883**
	Box-Cox	1.5341	**1.5866**	2.8203	1.6365
	Log1p	1.5028	1.6175	2.6887	1.7766
4*Cluster 2	None	1.5271	**1.4801**	1.9948	2.5474
	Diff	**1.3751**	1.6407	5.7676	**1.5357**
	Box-Cox	1.5032	1.4927	**1.9556**	2.5407
	Log1p	1.5260	1.5541	1.9948	2.5474

Результаты показывают, что влияние преобразований существенно зависит как от структуры временного ряда (кластера), так и от используемой модели. Сравнение результатов статистических моделей (ETS, Theta) и глобальной модели CatBoost позволяет выявить принципиальные различия в поведении моделей при различных преобразованиях.

14.1 1. Общая сравнительная картина

Наблюдается существенный разрыв в качестве прогнозирования:

- Статистические модели достигают sMAPE в диапазоне $[1.3, 2.5]$
- CatBoost демонстрирует существенно худшие результаты: $[4.0, 6.5]$

Это указывает на то, что в рассматриваемой задаче локальные модели лучше адаптируются к структуре отдельных рядов.

Таблица 2: Результаты глобальной модели CatBoost (sMAPE)

Кластер	Трансформация	CatBoost
4*Cluster 0	None	4.6834
	Diff	4.6289
	Box-Cox	177.8293
	Log1p	**4.3952**
4*Cluster 1	None	6.5049
	Diff	**4.0157**
	Box-Cox	149.4117
	Log1p	4.9166
4*Cluster 2	None	5.2031
	Diff	**4.9335**
	Box-Cox	191.4715
	Log1p	5.4736

14.2 2. Критическая нестабильность Box-Cox

Наиболее важное наблюдение:

- Box-Cox приводит к катастрофическому ухудшению качества для CatBoost:
  - Cluster 0: 177.8
  - Cluster 1: 149.4
  - Cluster 2: 191.5

Это свидетельствует о:

- численной нестабильности преобразования
- сильном искажении распределения таргета
- проблемах обратного преобразования (bias + масштаб)

При этом статистические модели не демонстрируют аналогичной деградации, что подчёркивает различие в чувствительности моделей.

14.3 3. Влияние дифференцирования

Дифференцирование показывает:

- Улучшение CatBoost в Cluster 1 (6.50 → 4.02)
- Умеренное улучшение в Cluster 2
- Почти нейтральный эффект в Cluster 0

Это согласуется с результатами ETS:

- дифференцирование эффективно для трендовых рядов

Однако в отличие от ETS:

- CatBoost не всегда способен корректно восстановить уровень ряда

14.4 4. Log1p как наиболее стабильное преобразование

Log1p демонстрирует:

- Лучший результат в Cluster 0
- Стабильное улучшение относительно baseline
- Отсутствие деградации

Это делает Log1p наиболее безопасным преобразованием для глобальных моделей.

14.5 5. Различие в поведении моделей

Ключевое различие:

- Статистические модели:
  - устойчивы к преобразованиям
  - используют явную декомпозицию (trend/seasonality)
- CatBoost:
  - чувствителен к масштабу и распределению
  - зависит от качества feature engineering
  - плохо переносит агрессивные преобразования

14.6 6. Роль кластеризации

Результаты подтверждают важность кластеризации:

- Cluster 1 и 2 выигрывают от differencing
- Cluster 0 лучше реагирует на log-преобразования

Это указывает на необходимость адаптивного выбора preprocessing pipeline.

14.7 7. Итоговые выводы

- Глобальная модель CatBoost уступает локальным статистическим моделям в данной задаче
- Box-Cox является неустойчивым преобразованием для ML моделей
- Log1p — наиболее стабильный выбор для глобальных моделей
- Differencing эффективно только для определённых типов рядов
- Кластеризация является ключевым инструментом для выбора трансформации

Таким образом, результаты демонстрируют, что выбор преобразования должен учитывать не только свойства ряда, но и тип используемой модели.

15 Воспроизводимость

Для обеспечения воспроизводимости:

- весь код доступен в репозитории
- фиксированы random seed
- описаны версии библиотек
- Запустить эксперименты можно в ноутбуке *analysis_results.ipynb*, либо же через файл *run_experiment.py*